

Taller 1: Análisis Predictivo y Aprendizaje Estadístico

Caso de Estudio: Advertising Data - - Impacto de la Inversión Publicitaria en Ventas

Laura Daniela Mora Pabón, 122700

Zuly Geraldine Salazar Beltrán, 123403

Adriana Marcela Velásquez Salinas, 114128

Universidad ECCI

Facultad de Ingeniería

Ingeniería Industrial - Sistemas Avanzados de Producción

Ingeniero: Fredy Alexander Orjuela Lopez

Bogotá, Colombia

1 de marzo de 2026

Contenido

INTRODUCCIÓN	5
OBJETIVOS ESPECÍFICOS	5
DESARROLLO TÉCNICO	6
FASE 1: Estadística Descriptiva y Análisis Exploratorio	6
1. Caracterización Numérica	6
Medidas de Tendencia Central y Dispersión.	6
2. Análisis de Distribución y Atípicos:	7
Simetría de las distribuciones:.....	7
Identificación de datos atípicos:.....	7
Influencia en la regresión lineal:.....	8
3. Exploración de la Nube de Puntos	8
Ventas vs TV:	8
Ventas vs Radio:	9
Ventas vs Periódico:	9
4. Evaluación de Asociación	10
5. Interpretación de Resultados	11
• Coeficientes cercanos a 1	11
• Coeficientes cercanos a 0	11
• Comparación Pearson vs Spearman	11
Implicación práctica	12
FASE 2: REGRESION LINEAL Y DIAGNOSTICO	12
1. Modelamiento Múltiple	12
Nota sobre la notación	13
Validación del modelo	13

2.	Interpretación de Parámetros	13
	Intercepto ($\beta_0 = 2.9389$)	13
	Coeficiente de TV ($\beta_1 = 0.0458$)	13
	Coeficiente de Radio ($\beta_2 = 0.1885$)	14
	Coeficiente de Newspaper ($\beta_3 = -0.0010$)	14
3.	Análisis de Bondad de Ajuste	14
	Comparación con los modelos simples de la Fase 1	15
	Análisis de la mejora	15
4.	Estimación Matricial	16
FASE 3: ÁRBOLES DE DECISIÓN Y COMPARACIÓN DE MODELOS		18
1.	Entrenamiento del Modelo	18
	Criterio de partición: Minimización del MSE	18
	Análisis de las Particiones	19
2.	Cálculo Manual de Incertidumbre (Clasificación)	20
	Datos del ejercicio (4 mercados):	20
	Nodo Izquierdo (TV = Alta):	21
	Nodo Derecho (TV = Baja):	21
	Entropía ponderada después de la partición:	22
	Ganancia de Información:	22
3.	Importancia de Predictores	22
	Árbol de Regresión:	22
	Regresión Lineal:	23
4.	Diagnóstico Comparativo	23
	Escenarios preferibles para cada modelo:	24
	Análisis del caso específico - Advertising Data	25

CONCLUSIONES	27
--------------------	----

REFERENCIAS.....	28
------------------	----

Tabla 1: Medidas de Tendencia Central y Dispersión.....	6
--	---

Tabla 2: Datos para Comparación Person VS Spearman	11
--	----

Tabla 3: Coeficientes estimados obtenidos del modelo de regresión lineal múltiple.....	12
--	----

Tabla 4: Comparación del coeficiente de determinación (R^2) por modelo	15
--	----

Tabla 5: Segmentación de mercados según condiciones del modelo	20
--	----

Tabla 6: Clasificación de mercados según inversión en TV y nivel de ventas	20
--	----

Tabla 7: Importancia de Variables por Modelo	22
--	----

Tabla 8: Comparación entre Regresión Lineal y Árbol de Decisión	24
---	----

Ilustración 1: Histograma de TV (izquierda), Radio (Centro-izquierda), Newspaper (Centro-derecha) y Ventas (derecha)	7
--	---

Ilustración 2: Boxplot de TV (izquierda), Radio (Centro-izquierda), Newspaper (centro-derecha) y Ventas (derecha)	7
---	---

Ilustración 3: Regresión Lineal Simple de Ventas VS TV	8
--	---

Ilustración 4: Regresión Lineal Simple de Ventas VS Radio	9
---	---

Ilustración 5: Regresión Lineal Simple de Ventas VS Periódico	9
---	---

Ilustración 6: Matriz de Correlación de Pearson	10
---	----

Ilustración 7: Matriz de Correlación de Spearman	11
--	----

INTRODUCCIÓN

En el entorno empresarial actual, la toma de decisiones basada en datos se ha convertido en un factor crítico para la competitividad. Una de las preguntas más recurrentes en el área de marketing y ventas es: ¿Cuál es el impacto real de la inversión publicitaria en las ventas? Comprender esta relación permite a las empresas optimizar la asignación de presupuestos y maximizar el retorno sobre la inversión (ROI).

El presente taller aborda esta problemática utilizando el conjunto de datos "Advertising", que contiene registros de ventas en 200 mercados diferentes, junto con los presupuestos destinados a tres canales publicitarios: TV, Radio y Newspaper. El objetivo principal es desarrollar habilidades para identificar asociaciones significativas entre la publicidad y el éxito comercial, cuantificar la magnitud de dichas relaciones y evaluar la capacidad predictiva de distintos modelos estadísticos.

OBJETIVOS ESPECÍFICOS

1. Realizar un análisis exploratorio de datos para identificar patrones, distribuciones y posibles outliers.
2. Construir y validar un modelo de regresión lineal múltiple que relacione las ventas con la inversión en los tres medios publicitarios.
3. Implementar un árbol de regresión para capturar relaciones no lineales y posibles efectos de interacción entre variables.
4. Comparar ambos enfoques (paramétrico vs no paramétrico) en términos de interpretabilidad y precisión predictiva.
5. Traducir los resultados estadísticos a recomendaciones de negocio accionables.

El informe se estructura en tres fases fundamentales que cubren el ciclo de vida de un proyecto de analítica: (1) Estadística Descriptiva y Análisis Exploratorio, (2) Regresión Lineal y Diagnóstico, y (3) Árboles de Decisión y Comparación de Modelos. Cada fase incluye el desarrollo técnico, el análisis crítico de resultados y su interpretación en el contexto del negocio.

DESARROLLO TÉCNICO

FASE 1: Estadística Descriptiva y Análisis Exploratorio

1. Caracterización Numérica

Se realizó la carga del dataset Advertising.csv y se verificó la ausencia de valores nulos. A continuación, se presenta la tabla con un resumen estadístico para las variables de TV, Radio, Newspaper y Sales:

Medidas de Tendencia Central y Dispersión.

Tabla 1: Medidas de Tendencia Central y Dispersión

Variable	Mean	Median	Std	Min	Max	Skewness	Kurtosis
TV	147.0425	149.75	85.854236	0.7	296.4	-0.069853	-1.226495
Radio	23.2640	22.90	14.846809	0.0	49.6	0.094175	-1.260401
Newspaper	30.5540	25.75	21.778621	0.3	114.0	0.894720	0.649502
Sales	14.0225	12.90	5.217457	1.6	27.0	0.407571	-0.408869

La tabla 1 nos da una primera radiografía de los datos. Observamos que la inversión en **TV** tiene la media más alta (147 mil dólares) y la mayor variabilidad (desviación estándar de 85.85), lo que indica que los presupuestos de **TV** fluctúan ampliamente entre los 200 mercados. Las ventas (**Sales**) promedian 14,022 unidades, con una desviación de 5,217, mostrando una variabilidad moderada. Los valores de asimetría (Skewness) cercanos a cero para **TV** y **Radio** sugieren distribuciones relativamente simétricas, mientras que **Newspaper** (0.89) tiene una asimetría positiva, lo que significa que hay algunos mercados con inversiones excepcionalmente altas en periódicos que jalan la media hacia la derecha.

2. Análisis de Distribución y Atípicos:

Ilustración 1: Histograma de TV (izquierda), Radio (Centro-izquierda), Newspaper (Centro-derecha) y Ventas (derecha)





Ilustración 2: Boxplot de TV (izquierda), Radio (Centro-izquierda), Newspaper (centro-derecha) y Ventas (derecha)



Simetría de las distribuciones:

- **TV:** Distribución relativamente simétrica con tendencia bimodal.
- **Radio:** Distribución altamente simétrica, cercana a la normal.
- **Newspaper:** Distribución con marcada asimetría positiva (sesgo a la derecha), indicando que la mayoría de los mercados invierten poco en este medio, pero existen algunos con inversiones muy elevadas.
- **Sales:** Distribución aproximadamente simétrica, aunque con una ligera asimetría positiva.

Identificación de datos atípicos:

- **TV y Radio:** No se identifican datos atípicos significativos en los boxplots, lo que sugiere que las inversiones en estos medios son consistentes en todos los mercados.
- **Newspaper:** Se observan múltiples outliers en la parte superior del boxplot, correspondientes a mercados con inversiones excepcionalmente altas (por encima de aproximadamente 70-80 mil dólares).
- **Sales:** Se identifican algunos outliers tanto en la parte superior (ventas muy altas) como posiblemente en la inferior (ventas muy bajas).

Influencia en la regresión lineal:

Los outliers identificados en Newspaper y Sales pueden tener un impacto significativo en un modelo de regresión lineal:

- Los outliers en Newspaper (variable predictora X) ejercen un alto apalancamiento (leverage), lo que significa que pueden "jalar" la línea de regresión hacia sí mismos, distorsionando la verdadera relación entre la inversión en periódicos y las ventas.
- Los outliers en Sales (variable respuesta Y) aumentan la varianza del error y pueden afectar la precisión de las predicciones, además de influir en el valor de los coeficientes estimados.


Es fundamental evaluar si estos outliers corresponden a errores en los datos o si representan estrategias de mercado legítimas pero atípicas. En cualquier caso, su presencia justifica un análisis de diagnóstico más profundo y posiblemente el uso de métodos robustos o transformaciones de variables.

3. Exploración de la Nube de Puntos

Se generaron dispersogramas (scatter plots) de la variable respuesta Ventas (Sales) frente a cada covariable:

Ventas vs TV:


Ilustración 3: Regresión Lineal Simple de Ventas VS TV



Se observa una relación lineal positiva claramente definida. La nube de puntos sigue una tendencia ascendente con dispersión moderada, sugiriendo que TV es un buen predictor lineal de las ventas. El R^2 de 0.612 en la regresión simple confirma esta observación visual.

Ventas vs Radio:


Ilustración 4: Regresión Lineal Simple de Ventas VS Radio



También se aprecia una relación positiva, pero la nube de puntos es considerablemente más dispersa. Esto indica que, aunque existe asociación, la relación es más débil y podría estar influenciada por otros factores (como la inversión en TV). El R^2 de 0.332 respalda esta observación.

Ventas vs Periódico:

Ilustración 5: Regresión Lineal Simple de Ventas VS Periódico



No se identifica un patrón lineal claro. Los puntos se distribuyen de manera aleatoria alrededor de una línea prácticamente horizontal, con presencia de outliers en el extremo derecho del eje X (alta inversión en periódicos). El R^2 de 0.052 confirma la ausencia de relación lineal significativa.

En conclusión, Los gráficos sugieren que la relación más fuerte y lineal se da con TV, seguida de Radio. Newspaper no muestra evidencia de relación lineal, lo que justifica un análisis más profundo en el modelo múltiple para evaluar si su efecto es relevante cuando se controlan las otras variables.

4. Evaluación de Asociación

Se presentan las siguientes matrices de correlación :

Ilustración 6: Matriz de Correlación de Pearson





Ilustración 7: Matriz de Correlación de Spearman



5. Interpretación de Resultados

- *Coeficientes cercanos a 1:* TV (0.78-0.80) y Radio (0.55-0.58) muestran asociaciones positivas fuertes a moderadas. Esto significa que invertir en estos medios está asociado con mayores ventas, siendo TV el de mayor impacto lineal.
- *Coeficientes cercanos a 0:* Newspaper (0.19-0.23) muestra una asociación muy débil, indicando que no hay evidencia de relación lineal entre la inversión en periódicos y las ventas.
- *Comparación Pearson vs Spearman:*

Tabla 2:Datos para Comparación Person VS Spearman

Variable	Pearson	Spearman	Diferencia
TV	0.78	0.80	+0.02
Radio	0.58	0.55	-0.03
Newspaper	0.23	0.19	-0.04

- La alta similitud en TV y Radio sugiere relaciones estrictamente lineales y ausencia de outliers distorsionantes.
- La ligera diferencia en Newspaper, aunque pequeña, refuerza que su relación con ventas es tan débil que podría deberse a ruido más que a una señal real.

Implicación práctica

Los resultados sugieren que los esfuerzos de marketing deben enfocarse en TV y Radio, ya que muestran asociaciones claras con ventas. La inversión en Newspaper, según estos datos, no presenta un retorno lineal evidente, por lo que su presupuesto podría ser reasignado a medios más efectivos.

FASE 2: REGRESION LINEAL Y DIAGNOSTICO

1. Modelamiento Múltiple

Se estimó un modelo de regresión lineal múltiple utilizando el método de Mínimos Cuadrados Ordinarios (OLS), donde la variable dependiente (Y) son las ventas (Sales), y las variables independientes (predictoras) son la inversión en TV, Radio y Newspaper. La especificación del modelo es:

$$Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \dots + \beta_p X_p + \epsilon$$

$$Sales = \beta_0 + \beta_1 * TV + \beta_2 * Radio + \beta_3 * Newspaper + \epsilon$$

Los coeficientes estimados obtenidos son:

Tabla 3: Coeficientes estimados obtenidos del modelo de regresión lineal múltiple

Parámetro	Variable	Coeficiente estimado	Valor
β_0	Intercepto	β_0	2.9389
β_1	TV	β_1	0.0458
β_2	Radio	β_2	0.1885
β_3	Newspaper	β_3	-0.0010

Por lo tanto, la ecuación de regresión estimada queda expresada como:

$$\text{Sales} = 2.9389 + 0.0458 * TV + 0.1885 * \text{Radio} - 0.0010 * \text{Newspaper}$$

Nota sobre la notación

Los coeficientes están expresados en las unidades originales de las variables:

- TV, Radio, Newspaper: miles de dólares (\$1,000 USD)
- Sales: miles de unidades (1,000 unidades)

Validación del modelo

El modelo se estimó utilizando la totalidad de las 200 observaciones del dataset Advertising, asegurando que no existían valores faltantes que pudieran sesgar los resultados. La bondad de ajuste del modelo ($R^2 = 0.8972$) indica que estas tres variables explican conjuntamente casi el 90% de la variabilidad en las ventas.

2. Interpretación de Parámetros

Intercepto ($\beta_0 = 2.9389$)

El intercepto representa las ventas esperadas (en miles de unidades) cuando la inversión en todos los medios publicitarios es cero. Según el modelo, si no se invierte en TV, Radio ni Newspaper, se venderían aproximadamente 2,939 unidades."

Este valor tiene sentido conceptual porque incluso sin publicidad, existen ventas base impulsadas por otros factores como reconocimiento de marca, recomendaciones, o necesidad del producto. Sin embargo, debemos ser cautelosos: en la realidad, ningún mercado tiene inversión cero en todos los medios simultáneamente, por lo que el intercepto es más un parámetro de ajuste matemático que una predicción realista.

Coeficiente de TV ($\beta_1 = 0.0458$)

Por cada \$1,000 adicionales invertidos en publicidad por TV, manteniendo constantes las inversiones en Radio y Newspaper (ceteris paribus), las ventas aumentan en promedio 45.8 unidades.

Esto significa que la TV tiene un retorno positivo. Si una empresa incrementa su presupuesto de TV en \$10,000, esperaría vender aproximadamente 458 unidades más.

Coeficiente de Radio ($\beta_2 = 0.1885$)

Por cada \$1,000 adicionales invertidos en Radio, manteniendo constantes TV y Newspaper, las ventas aumentan en promedio 188.5 unidades.

Aunque la inversión promedio en Radio (23.3 mil) es mucho menor que en TV (147 mil), el impacto marginal de Radio es más de 4 veces mayor (0.1885 vs 0.0458). Es decir, cada dólar invertido en Radio genera más retorno en ventas que el mismo dólar invertido en TV. Esto sugiere que, desde una perspectiva de optimización de presupuesto, podría valer la pena reasignar recursos hacia Radio.

Coeficiente de Newspaper ($\beta_3 = -0.0010$)

Por cada \$1,000 adicionales invertidos en Newspaper, manteniendo constantes TV y Radio, las ventas disminuyen en promedio 1 unidad.

El coeficiente es prácticamente cero (-0.001) y además negativo. Esto indica que, una vez que se considera el efecto de TV y Radio, la inversión en Newspaper no tiene un impacto lineal significativo en las ventas. El valor negativo es tan pequeño que podría deberse a ruido estadístico más que a un efecto real. Esto coincide con nuestro análisis exploratorio, donde Newspaper mostraba outliers y una correlación muy débil con ventas.

En conclusión, desde una perspectiva gerencial, esto sugiere que el presupuesto destinado a periódicos podría ser reasignado a TV o Radio para obtener un mejor retorno, a menos que existan razones estratégicas (llegar a audiencias específicas) para mantenerlo.

3. Análisis de Bondad de Ajuste

El coeficiente de determinación obtenido para el modelo de regresión lineal múltiple es:

$$R^2 = 0.8972$$

Este valor indica que aproximadamente el **89.72% de la variabilidad total en las ventas** (Sales) es explicada conjuntamente por las variables predictoras: inversión en TV, Radio y Newspaper.

En términos prácticos, significa que el modelo logra capturar casi el 90% de los factores que influyen en el comportamiento de las ventas, dejando solo un **10.28% de variabilidad no explicada**, la cual corresponde al término de error (ϵ) y a otros factores no incluidos en el modelo.

Comparación con los modelos simples de la Fase 1

Tabla 4: Comparación del coeficiente de determinación (R^2) por modelo

Modelo	R^2	Variables incluidas
Regresión simple TV	0.612	Solo TV
Regresión simple Radio	0.332	Solo Radio
Regresión simple Newspaper	0.052	Solo Newspaper
Regresión múltiple	0.897	TV + Radio + Newspaper

Análisis de la mejora

- **TV individual ($R^2 = 0.612$):** Ya explicaba el 61.2% de las ventas por sí sola, confirmando que es el predictor más importante.
- **Radio individual ($R^2 = 0.332$):** Por sí sola explica poco, pero al incluirla junto con TV, el R^2 salta de 0.612 a 0.897, lo que significa que Radio aporta un **incremento de 28.5 puntos porcentuales** en la capacidad explicativa del modelo. Esto es crucial porque, aunque Radio no es buen predictor individual, su **efecto conjunto con TV** es muy valioso. Esto sugiere posibles **sinergias** entre ambos medios.
- **Newspaper individual ($R^2 = 0.052$):** Apenas aporta poder explicativo por sí solo. En el modelo múltiple, su coeficiente cercano a cero (-0.001) y la pequeña mejora en R^2 al incluirlo (de 0.897 a 0.897, prácticamente igual) indican que **Newspaper no contribuye significativamente** una vez que ya están TV y Radio en el modelo.

En conclusión, la Radio mejoró significativamente el ajuste; a pesar de su bajo R^2 individual, su inclusión junto con TV aumentó drásticamente la capacidad predictiva, lo que justifica mantenerla en el modelo.

Por otra parte, el Newspaper no mejoró el ajuste; su contribución marginal es casi nula, lo que sugiere que, desde una perspectiva de parsimonia (modelo simple pero efectivo), esta variable podría excluirse sin perder poder predictivo significativo. Esto confirma los hallazgos del análisis exploratorio donde Newspaper mostraba correlación débil y presencia de outliers.

Desde la perspectiva gerencial, un R^2 de 0.897 nos da alta confianza en que el modelo captura adecuadamente la relación entre la inversión publicitaria y las ventas. Esto permite:

- Estimar con precisión el retorno de inversión (ROI) de cada medio.
- Optimizar la asignación del presupuesto de marketing.
- Tomar decisiones basadas en evidencia cuantitativa sólida.


4. Estimación Matricial

Dadas las matrices de diseño X y el vector de respuesta Y :

$$X = \begin{pmatrix} 1 & 1 \\ 1 & 2 \\ 1 & 3 \\ 1 & 4 \\ 1 & 5 \end{pmatrix}, \quad Y = \begin{pmatrix} 2 \\ 4 \\ 6 \\ 7 \\ 9 \end{pmatrix}$$


Tarea:

- Calcule la matriz transpuesta X'



$$X' = \begin{pmatrix} 1 & 1 & 1 & 1 & 1 \\ 1 & 2 & 3 & 4 & 5 \end{pmatrix}$$

- Calcule el producto $X'X$ y su respectiva matriz inversa $(X'X)^{-1}$



$$X'X = \begin{pmatrix} 1 & 1 & 1 & 1 & 1 \\ 1 & 2 & 3 & 4 & 5 \end{pmatrix} \times \begin{pmatrix} 1 & 1 \\ 1 & 2 \\ 1 & 3 \\ 1 & 4 \\ 1 & 5 \end{pmatrix} = \begin{pmatrix} 5 & 15 \\ 15 & 55 \end{pmatrix}$$

$1 \times 1 + 1 \times 1 + 1 \times 1 + 1 \times 1 + 1 \times 1 = 5$
 $1 \times 1 + 1 \times 2 + 1 \times 3 + 1 \times 4 + 1 \times 5 = 15$
 $1 \times 1 + 2 \times 1 + 3 \times 1 + 4 \times 1 + 5 \times 1 = 15$
 $1 \times 2 + 2 \times 2 + 3 \times 3 + 4 \times 4 + 5 \times 5 = 55$

$X'X = \begin{pmatrix} 5 & 15 \\ 15 & 55 \end{pmatrix}$

$$\bullet (X'X)^{-1} \rightarrow \frac{(\text{Adj } A)'}{\det A} \rightarrow \det A = 5 \cdot 55 -$$

$$A^{-1} = \frac{1}{5(55) - (15)(15)} = \frac{1}{275 - 225} = \frac{1}{50}$$

$$\left[\text{Adj } A = \begin{pmatrix} 55 & -15 \\ -15 & 5 \end{pmatrix} \right]' = \begin{pmatrix} 55 & -15 \\ -15 & 5 \end{pmatrix}$$

$$A^{-1} = \frac{1}{50} \begin{pmatrix} 55 & -15 \\ -15 & 5 \end{pmatrix} = \begin{pmatrix} 1,1 & -0,3 \\ -0,3 & 0,1 \end{pmatrix} \checkmark$$

$$(X'X)^{-1} =$$

- Calcule el producto $X'Y$.

$$\bullet X'Y = \begin{pmatrix} 1 & 1 & 1 & 1 & 1 \\ 1 & 2 & 3 & 4 & 5 \end{pmatrix} \times \begin{pmatrix} 2 \\ 4 \\ 6 \\ 7 \\ 9 \end{pmatrix} = \begin{pmatrix} 28 \\ 101 \end{pmatrix} \checkmark$$

$$1 \times 2 + 2 \times 1 + 3 \times 6 + 4 \times 7 + 5 \times 9$$

$$2 + 8 + 18 + 28 + 45 = 101$$

- Obtenga el vector de parámetros $\hat{\beta}$ y escriba la ecuación de la recta estimada $\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 x$

$$\bullet \text{Formula } \hat{\beta} = (X'X)^{-1} X'Y$$

¡Sustituimos!

$$\hat{\beta} = \frac{1}{50} \begin{pmatrix} 55 & -15 \\ -15 & 5 \end{pmatrix} \times \begin{pmatrix} 28 \\ 101 \end{pmatrix} = \begin{pmatrix} 1,1 & -0,3 \\ -0,3 & 0,1 \end{pmatrix} \times \begin{pmatrix} 28 \\ 101 \end{pmatrix}$$

$$\hat{\beta} = \begin{pmatrix} 30,8 - 30,3 \\ -8,4 + 10,4 \end{pmatrix} = \begin{pmatrix} 0,5 \\ 1,7 \end{pmatrix} \checkmark$$

$\beta_0 = 0,5 \rightarrow \text{intercepto}$


$\beta_1 = 1,7 \rightarrow \text{pendiente}$

FASE 3: ÁRBOLES DE DECISIÓN Y COMPARACIÓN DE MODELOS

1. Entrenamiento del Modelo

Se entrenó un árbol de regresión utilizando las variables **TV** y **Radio** para predecir las ventas (Sales). A continuación, se presenta la estructura del árbol obtenido y la explicación del criterio de partición:

Estructura del Árbol de Regresión: Ventas vs (TV y Radio)



A diferencia de los árboles de clasificación que buscan reducir el desorden (Gini/Entropía), el árbol de regresión busca reducir la **Variabilidad Numérica** de la variable respuesta. Su objetivo es segmentar los datos de tal forma que las **Ventas (Sales)** en cada grupo sean lo mas parecido posible entre sí. En lugar de predecir una clase (alta/baja), el modelo predice un **valor numérico promedio** en cada nodo

Criterio de partición: Minimización del MSE

En cada nodo del árbol, el algoritmo evalúa todas las variables predictoras, en este caso **TV** y **Radio**, y todos los posibles de corte, buscando la combinación que minimice el **Error Cuadrático Medio ponderado (MSE)**

Su fórmula es:

$$MSE_{Total} = \frac{n_{izq}}{n} MSE_{izq} + \frac{n_{der}}{n} MSE_{der}$$

Donde:

- n_{izq} = número de observaciones en el nodo izquierdo
- n_{der} = número de observaciones en el nodo derecho
- n = total de observaciones en el nodo actual
- MSE_{izq} = error cuadrático medio del grupo izquierdo
- MSE_{der} = error cuadrático medio del grupo derecho

Análisis de las Particiones

Nodo Raíz (Primera partición):

- Variable seleccionada: TV
- Punto de corte: $TV \leq 122.05$
- MSE antes de dividir: 27.09

Resultado:

- Nodo izquierdo ($TV \leq 122.05$): 83 mercados, ventas promedio = 9.78
- Nodo derecho ($TV > 122.05$): 117 mercados, ventas promedio = 17.04

Esta división es la que más reduce la variabilidad total. Los mercados con inversión en TV por debajo de 122.05 tienen ventas significativamente más bajas (9.78 vs 17.04). El algoritmo encontró que este corte separa mejor los datos que cualquier corte en Radio.

Segundo nivel de particiones:

- **Nodo izquierdo (TV baja):** La siguiente partición es nuevamente por $TV \leq 30.05$, lo que indica que, incluso dentro de los mercados de baja TV, el nivel exacto de inversión sigue siendo el factor más discriminante. Los mercados con muy baja TV (≤ 30.05) tienen ventas de 9.78, mientras que los que están entre 30.05 y 122.05 tienen ventas de 11.16.
- **Nodo derecho (TV alta):** Aquí aparece Radio como variable de partición ($Radio \leq 26.85$). Esto revela un patrón importante: una vez que la inversión en TV es alta, el nivel de Radio comienza a ser relevante. Los mercados con Radio bajan (≤ 26.85) tienen ventas de 13.64, mientras que los de Radio alta tienen ventas de 20.74.

Interpretación de las hojas (nodos terminales):

Tabla 5: Segmentación de mercados según condiciones del modelo

Segmento	Condiciones	# Mercados	Ventas promedio	MSE
S1	$TV \leq 8.65$	26	6.74	2.50
S2	$TV > 8.65$ y $TV \leq 30.05$ y $Radio \leq 27.1$	39	10.26	1.71
S3	$TV > 122.05$ y $Radio > 26.85$ y $TV \leq 194.55$	39	21.95	5.86

Esto significa que los mercados con muy baja inversión en TV (menos de \$8,650) tienen ventas promedio de 6,740 unidades, con un error típico de predicción representado por el error cuadrático.

2. Cálculo Manual de Incertidumbre (Clasificación)

Datos del ejercicio (4 mercados):

Tabla 6: Clasificación de mercados según inversión en TV y nivel de ventas

Mercado	Inversión TV	Ventas (Clase)
1	Alta	Altas
2	Alta	Altas
3	Baja	Bajas
4	Baja	Altas

Tarea:

- Calcule la Entropía del Nodo Padre: $H(S) = -\sum p_i \log_2(p_i)$

Distribución de clases:

- Ventas Altas: 3 mercados $\rightarrow p(\text{Altas}) = 3/4 = 0.75$
- Ventas Bajas: 1 mercado $\rightarrow p(\text{Bajas}) = 1/4 = 0.25$

$$H(S) = - \sum p_i \log_2(p_i)$$

$$H(S) = -[0,75 * \log_2(0,75) + 0,25 * \log_2(0,25)]$$

$$\log_2(0,75) \approx -0,415, \quad \log_2(0,25) \approx -2$$

$$H(S) = -[0,75 * (-0,415) + 0,25 * (-2)]$$

$$H(S) = -[-0,31125 - 0,5]$$

$$H(S) = -[-0,81125]$$

$$H(S) = 0,8113 \text{ bits}$$

- Calcule el Índice de Gini del Nodo Padre: $Gini = 1 - \sum p_i^2$

$$Gini = 1 - \sum p_i^2$$

$$Gini = 1 - [(0,75)^2 + (0,25)^2]$$

$$Gini = 1 - [0,5625 + 0,0625]$$

$$Gini = 1 - 0,625$$

$$Gini = 0,375$$

- Determine la Ganancia de Información tras realizar una partición por la variable *Inversión TV*:

Nodo Izquierdo (TV = Alta): 2 mercados, ambos con Ventas Altas

$$H(Izq) = -[1 \cdot \log_2(1) + 0 \cdot \log_2(0)]$$

$$H(Izq) = 0$$

Nodo Derecho (TV = Baja): 2 mercados, 1 Alto y 1 Bajo

$$H(Der) = -[0,5 \cdot \log_2(0,5) + 0,5 \cdot \log_2(0,5)]$$

$$H(Der) = -[0,5 \cdot (-1) + 0,5 \cdot (-1)]$$

$$H(Der) = 1$$

Entropía ponderada después de la partición:

$$H(S, TV) = \frac{2}{4} * 0 + \frac{2}{4} * 1$$

$$H(S, TV) = 0,5$$

Ganancia de Información:

$$IG = H(S) - H(S, TV)$$

$$IG = 0,8113 - 0,5$$

$$IG = 0,3113 \text{ bits}$$

La partición por la variable *Inversión TV* reduce la incertidumbre inicial en **0.3113 bits**. El nodo izquierdo (TV Alta) es puro (entropía 0), mientras que el nodo derecho aún tiene mezcla de clases. Esta ganancia de información positiva justifica la inclusión de esta variable en el árbol de decisión.

3. Importancia de Predictores

Se comparó la importancia de las variables TV y Radio en dos modelos diferentes: el árbol de regresión y la regresión lineal múltiple (con las tres variables, pero enfocándonos en TV y Radio para la comparación).

Tabla 7: Importancia de Variables por Modelo

Modelo	Importancia TV	Importancia Radio
Árbol de Regresión	0.6425 (64.25%)	0.3575 (35.75%)
Regresión Lineal (coeficientes estandarizados)	0.0458	0.1880

Árbol de Regresión:

- TV domina con un 64,25% de importancia
- Radio aporta el 35,75% restante

Esto significa que, para segmentar los mercados y predecir ventas, el árbol encuentra que TV es el factor más determinante, pero Radio también juega un papel relevante, especialmente en

mercados con alta inversión en TV (como se vio en la estructura del árbol, donde Radio aparece en el nodo derecho)

Regresión Lineal:

- Coeficiente de TV es de 0,0458 es decir, cada \$1.000 en TV aumentan a 45,8 und
- Coeficiente de Radio es de 0,1880 es decir, cada \$1.000 en Radio aumentan a 188 und

El coeficiente de Radio es más de 4 veces mayor que el de TV, lo que indica que, en términos marginales, cada dólar invertido en Radio genera más retorno en ventas.

La diferencia entre los dos métodos radica en lo que mide, es decir; el **Árbol de Regresión** mide la frecuencia con que una variable es usada para particionar y la mejora en pureza que aporta. TV aparece primero y en múltiples niveles porque tiene mayor poder para segmentar los mercados en grupos homogéneos.

Por otra parte, el método de la **Regresión Lineal** mide el cambio promedio en ventas por unidad adicional invertida, manteniendo lo demás constante. Radio tiene un coeficiente mayor porque, una vez controlado el efecto de TV, su impacto marginal es más fuerte.

En conclusión, ambos modelos coinciden en que TV es el predictor más importante en términos globales. Sin embargo, la regresión lineal revela que Radio tiene un mayor retorno marginal, lo que tiene implicaciones importantes para la asignación de presupuesto.

4. Diagnóstico Comparativo

A partir de los resultados obtenidos a lo largo del taller, se presenta un análisis comparativo entre los dos enfoques de modelamiento:

Tabla 8: Comparación entre Regresión Lineal y Árbol de Decisión

<i>Criterio</i>	<i>Regresión Lineal</i>	<i>Árbol de Decisión</i>
<i>Interpretabilidad</i>	ALTA: coeficientes directos ("cada \$1.000 en TV aumenta ventas en 45.8 unidades")	MEDIA: la estructura es visualizable, pero requiere seguir múltiples ramas
<i>Relaciones capturadas</i>	Lineales únicamente	No lineales e interacciones entre variables
<i>Importancia de variables</i>	TV (0.0458), Radio (0.1880) – Radio tiene mayor coeficiente	TV (64.25%), Radio (35.75%) – TV domina
<i>Robustez a outliers</i>	BAJA: sensible a valores extremos	ALTA: particiona por rangos, menos sensible
<i>Supuestos requeridos</i>	Linealidad, normalidad, homocedasticidad, independencia	Ninguno (no paramétrico)
<i>Precisión predictiva</i>	Buena para relaciones lineales simples	Mejor cuando hay interacciones complejas
<i>Capacidad de generalización</i>	Puede extrapolar fuera del rango (con riesgo)	No extrapola, solo predice dentro del rango observado

Escenarios preferibles para cada modelo:

- ¿Cuándo usar Regresión Lineal?
- Cuando se necesita explicar el impacto marginal de cada variable a la gerencia: "por cada \$1,000 adicionales en Radio, las ventas aumentan en 188 unidades".
- Cuando la relación entre variables es aproximadamente lineal (como se observó en TV vs Ventas con $R^2=0.612$).
- Para inferencia estadística: probar hipótesis sobre coeficientes, construir intervalos de confianza.
- Cuando la interpretabilidad y la comunicación a stakeholders no técnicos es prioridad.
- Cuando se requiere parsimonia: un modelo simple pero efectivo.

- ¿Cuándo usar Árboles de Decisión?
 - Cuando existen relaciones no lineales o efectos umbral (ej: la TV solo es efectiva después de cierta inversión, como sugiere el primer corte en $TV=122.05$).
 - Cuando hay interacciones entre variables (ej: el efecto de Radio depende del nivel de TV, como se observa en que Radio solo aparece en el nodo derecho del árbol).
 - Cuando se prioriza la precisión predictiva sobre la interpretabilidad.
 - Para segmentación natural de mercados: el árbol agrupa mercados con comportamientos similares (ej: mercados con TV baja vs TV alta).
 - Cuando no se quiere asumir una forma funcional predefinida.

Análisis del caso específico - Advertising Data

En este dataset, ambos modelos aportan perspectivas complementarias:

- Lo que revela la Regresión Lineal:
 - El intercepto (2.94) indica ventas base sin publicidad.
 - Radio tiene el mayor impacto marginal (0.1885), sugiriendo que es el medio más rentable en el margen.
 - Newspaper es prácticamente irrelevante (-0.0010), lo que sugiere reasignar su presupuesto.
 - El R^2 de 0.897 indica que el modelo lineal captura bien la estructura de los datos.
- Lo que revela el Árbol de Decisión:
 - TV es el principal segmentador de mercados (primer corte en 122.05).
 - Existe un efecto umbral: mercados con $TV \leq 122.05$ tienen ventas muy diferentes (9.78) a los con $TV > 122.05$ (17.04).
 - Radio solo es relevante cuando la inversión en TV es alta (aparece en el nodo derecho), sugiriendo una ****sinergia**** entre ambos medios.
 - La segmentación permite identificar perfiles de mercado: "mercados de baja inversión", "mercados de inversión media con Radio baja/alta", etc.

En conclusión, para este caso en particular, el enfoque óptimo sería híbrido, es decir:

Utilizar la regresión lineal para:

- Cuantificar el retorno marginal de cada medio (útil para decisiones de presupuesto).

- Comunicar resultados a la gerencia de manera clara y accionable.
- Validar la significancia estadística de las relaciones.

Utilizar el árbol de decisión para:

- Identificar segmentos de mercado con comportamientos atípicos.
- Descubrir interacciones y efectos umbral no evidentes en la regresión.
- Validar si la relación es realmente lineal o si hay patrones más complejos.

Considerando los resultados, la regresión lineal es más robusta para explicar y cuantificar el fenómeno, dado que los datos muestran una fuerte componente lineal y el modelo alcanza un R^2 de 0.897. Sin embargo, el árbol de decisión es más robusto para descubrir patrones ocultos y segmentar mercados. La combinación de ambos ofrece la visión más completa para la toma de decisiones.

CONCLUSIONES

A partir del análisis desarrollado a lo largo del taller, se derivan las siguientes conclusiones:

1. Se confirmó una fuerte asociación positiva entre la inversión en TV y Radio con las ventas.
El modelo de regresión múltiple alcanzó un R^2 de 0.897, indicando que casi el 90% de la variabilidad en ventas es explicada por estos tres medios.
2. Importancia de cada medio
 - TV es el predictor más importante en términos de segmentación de mercados (64% de importancia en el árbol) y explica por sí sola el 61.2% de la variabilidad en ventas.
 - Radio, aunque su poder explicativo individual es menor ($R^2=0.332$), tiene el mayor impacto marginal (coeficiente de 0.1885), lo que significa que cada dólar invertido en Radio genera más retorno que el mismo dólar en TV.
 - Newspaper; No mostró una relación significativa con las ventas (coeficiente ≈ 0 , R^2 individual de 0.052), sugiriendo que su presupuesto podría ser reasignado a medios más efectivos.
3. Se identificaron outliers en Newspaper y en Ventas. Los outliers en Newspaper tienen alto leverage y podrían estar distorsionando la relación lineal, lo que justifica un análisis más profundo o el uso de métodos robustos.
4. El árbol de regresión reveló que Radio solo es relevante cuando la inversión en TV es alta (aparece en el nodo derecho), sugiriendo una **sinergia** entre ambos medios: la Radio es más efectiva cuando ya hay una base sólida de inversión en TV.
5. Ambos modelos son complementarios: la regresión responde "cuánto" y el árbol responde "cómo se agrupan".

Comparación de Modelos

Aspecto	Regresión Lineal	Árbol de Decisión
Fortaleza	Cuantifica impacto marginal	Identifica segmentos e interacciones
Debilidad	Asume linealidad	Menor interpretabilidad para impacto marginal
Mejor uso	Decisiones de presupuesto	Segmentación de mercados

REFERENCIAS

- (Google Colab, s. f.) Semana 3 y 4
- Coeficiente de correlación: definición sencilla, fórmula y pasos sencillos, s.f. Statistics How To. (2024). Recuperado de <https://www.statisticshowto.com/probability-and-statistics/correlation-coefficient-formula/>
- Minitab Blog Editor. (s. f.). Análisis de regresión: ¿Cómo interpreto el R cuadrado y evalúo la bondad del ajuste? <https://blog.minitab.com/en/adventures-in-statistics-2/regression-analysis-how-do-i-interpret-r-squared-and-assess-the-goodness-of-fit>
- PennState Eberly College of Science. (2024). ESTADISTICA 462: Análisis de regresión aplicado - Valores atípicos y puntos influyentes. Recuperado de <https://online.stat.psu.edu/stat462/node/172/>